연주 설비 고장 위험 예측
전처리 데이터셋 구축 및 모델링 작업 보고서

POSKO 예지보전 합성 데이터 (pdm-v2.2.0) · CH.4 · 작성일 2026-10-15

1. 요약

항목	내용
프로젝트 목표	서비스 기능 6개(고장 위험 예측, 이상 탐지·조기 경보, 상태·원인 진단, 잔여수명 추정, 정비 시점·정책 비교, 공정 품질·최종 결함 예측)를 진행할 수 있는 전처리 데이터셋을 만들고, 팀 분담에서 맡은 1번 파트 고장 위험 예측을 연주 설비로 구현
수행 내용	① 원본 데이터 구조 분석 ② 시나리오 단위 전처리 파이프라인 ③ 시나리오별 전처리 데이터셋(3.0GB) ④ 연주 설비 6시간·24시간 고장 위험 모델 ⑤ 결과 해석용 그림과 독립 검증
핵심 결과	연주 24시간 위험: PR-AUC 0.76 (찍는 수준 0.11). 재현율 0.8 이상을 지키면 정밀도는 약 0.68 (랜덤 포레스트, train으로 정한 임계값)
주의	합성 데이터이고 validation의 고장 표본이 적어서(24시간 70건, 6시간 16건) 수치의 불확실성이 큼

한 줄 요약 센서 값이 갑자기 튀는 이상치는 없고, 열화는 값이 한쪽으로 서서히 이동하는 형태(CONTROL_DELAY 상승, OSC-STK 하락, MLD-LVL 변동)로 나타난다. 모델은 이 변화를 보고 고장 70건 중 52건을 헛경보 11번으로 미리 잡는다(24시간, 시험 데이터).

2. 데이터 개요

- 합성 데이터: 시뮬레이터로 만든 가상 데이터(manifest의 synthetic 표시). 정해진 열화·고장 규칙에 따라 센서 값이 만들어지며 정답지도 그 규칙과 일치
- 시나리오 360개, 각 72시간. train 216 / validation 72 / test 72 (시작 시각순 분할). 시나리오 사이에 24시간 간격이 있고 서로 이어지지 않는 독립된 실험. 연주 설비 기준으로 앞 시나리오가 열화 상태로 끝난 61건 중 다음 시나리오가 열화로 시작한 경우는 0건
- 한 시나리오 안에서 설비 7개가 같은 72시간 시계를 공유. 설비마다 측정 주기가 다름
- 원본은 시나리오·원자료 종류별로 쪼갠 청크(해시 이름 CSV, 약 4MB)로 배포. 청크는 한 시나리오의 일부이며 청크 4,330개, 24,207,546행을 전수 확인한 결과 다른 시나리오의 행은 0개

설비	이름	측정 주기	시나리오당 행 수	비고
A	소둔로	30초	8,640	원자료 annealing
B	용접기	10분 (코일당 13행)	5,616	welding
C	연주(주조)	5초	51,840	casting, 이번 모델링 대상
D	조질압연	5분	864	요약 통계(temper-features)
E1, E2	소결 배풍기 1·2	2시간	각 36	요약 통계(fan-features), 병렬 설비
F	교반기	30분	144	요약 통계(agitator-features)

원본 폴더	내용	규모	용도
chunks/ + manifest.json	센서 데이터와 색인	청크 4,330개	전처리 입력
diagnostics/	상태 구간(정상·열화·고장·정비), 원인 부품, 고장 모드	288개 시나리오	상태·원인 진단, 열화 시작 시각
labels/	6·24시간 고장 위험 정답	288개, 시나리오당 91행	고장 위험 예측
targets/	잔여수명, 검열, 정비 정책 정답과 비용 점수	288개, 시나리오당 91행	잔여수명, 정비 정책
flow/	작업 흐름(operations), 품질 지표(inspections), 결함 정답(quality)	360 / 360 / 288개	공정 품질·최종 결함
정비 이력 (청크 안)	정비, 교체, 부품, 정비 계획, 운전 조건 변경, 설비 목록	6종, 시나리오당 소량	정비 정책의 입력

※ 가진 데이터는 원본의 LITE 복사본으로 원자료 12종(원본 17종, 원시 파형 제외)이며 4,330개 청크, 24,207,546행입니다.

3. 전처리

3.1 구조 결정 과정

- 시도 1: 설비별로 전 시나리오를 합친 CSV(연주 2.2GB, 18,662,400행)와 시나리오별 Parquet 변환 → 합쳤다가 다시 나누는 중복이라 폐기
- 시도 2: 시나리오 전체를 훑어 의심 청크만 열어서 탐지하는 2단계 구조 → 결측 1,080행 중 134행(12.4%)만 점검되어 결측의 87.6%를 놓침. 선택 기준이 이상 센서가 아니라 설비 정지 시간에 끌려가는 문제도 확인
- 최종: 시나리오 하나씩 청크를 모두 이어 붙여 같은 기준으로 전수 점검. 청크를 pandas로 직접 읽으면 연주 전체(1,866만 행)를 약 10초에 읽음. 전체 7개 설비 점검은 5분 내외

3.2 전처리 기준 (센서 데이터)

항목	기준	근거
결측	센서 열이 비었거나 QUALITY_FLAG가 ok가 아닌 행 → IS_MISSING	데이터 설명서
결측 채우기	연속 3행 이하만 바로 앞 값으로 채움, 더 길거나 맨 앞은 그대로	기존 팀 코드의 값
정지	RUNNING = 0 → IS_STOPPED (D·E·F는 가동 열이 없어 해당 없음)	데이터 설명서
정비 구간	정비 이력의 시작 ≤ 시각 < 종료 → IS_MAINTENANCE (종료가 공란이면 관측 끝까지)	데이터 확인: D·E·F의 0값이 정비 구간 안에서만 발생
이상치	정지·결측·정비 행을 뺀 뒤 직전 11개 값(E는 5개)의 중앙값에서 MAD의 10배 이상 벗어남 → IS_OUTLIER. 같은 슬라브·로트·코일·용접 위치 안에서만 비교, 직전 값만 사용, 척도 하한은 중앙값의 1%	10배는 비교 실험으로 결정, 11개와 1%는 임의 설정 (설정 파일에 모음)
원칙	행을 삭제하지 않고 값도 바꾸지 않음(채운 칸 제외). 이상치는 표시만 함	

나머지 원본(정답, flow, 정비 이력)은 값을 바꾸지 않고 시나리오 폴더로 옮기며 정리만 했습니다: 시각 형식 통일, 원본 글자 그대로 보존, ROW_ID와 시나리오 시작 기준 경과 초 추가, 정답 열에는 GT_ 접두사(모델 입력에서 제외할 열 표시), 검열 빈칸은 채우지 않음.

3.3 설비별 전처리 결과

설비	행 수	정지 행	정비 구간 행	결측 행 (채움)	이상치 행	판정 가능 비율
A	3,110,400	30,082	30,000	3,600 (3,600)	6	95.4%
B	2,021,760	20,020	19,981	0	1,469	94.9%
C	18,662,400	575,558 (3.08%)	574,560	1,080 (1,080)	0	96.9%
D	311,040	0	2,967	0	738	97.4%
E1	12,960	0	128	0	13	71.9%
E2	12,960	0	129	0	6	71.9%
F	51,840	0	502	0	35	84.6%

※ 판정 가능 비율: 이상치 판정 대상 행 중 직전 값 기준이 계산되는 행의 비율(시나리오 시작 구간은 판정 불가).

- 연주(C)에는 이상치 판정 행이 0개. 가장 튄 값도 CONTROL_DELAY 9.2배(S0092)로 기준 10배 바로 아래이고 나머지 센서는 2.6배 이하. 합성 데이터에 무작위 튀는 값이 없는 것으로 보임(추정)
- 결측은 A와 C에만 있고 전부 연속 3행 이하여서 모두 채움. 연주 결측률은 0.006%
- 시나리오 훑어보기(참고): 정지 행을 뺀 WD-SPD 평균이 평소와 달라서 정답이 있는 열화 시나리오 81개 중 66개를 포착(오탐 5/207). 고장 모드별 포착률은 friction 78%, sticking 69%, control-delay 96%. 시나리오 전체 평균이라 예측 입력으로는 쓸 수 없음

4. 전처리 데이터셋

시나리오 360개를 폴더 하나씩으로 묶고, 설비 7개 파일과 함께 정답·흐름·정비 이력을 같은 폴더에 두었습니다 (Data/Processed/Scenarios, 3.0GB).

위치 (S0001 폴더 기준)	내용	개수
A.csv ~ F.csv (7개)	센서 데이터 + IS_ 표시 4개 + 경과 초(T_SEC) + 상태 정답 GT_ 열 3개	2,520개
diagnostics.csv / labels.csv / targets.csv	정답 3종 (원본처럼 폴더 없이 바로 아래)	각 288개 (train·validation만)
flow/ operations, inspections, quality	작업 흐름, 작업 후 품질 지표, 결함 정답(GT_)	360 / 360 / 288개
history/ (6종)	정비 이력, 교체 내역, 부품, 정비 계획, 운전 조건 변경, 설비 목록	2,160개
Scenarios/index.csv	시나리오 목록, 분할, 시작 시각, 파일별 행 수	1개

- 사용 규칙: GT_ 열은 정답이므로 입력에서 제외 / 시각이 있는 행(flow, history 등)은 예측 시점 이전의 것만 사용 / 분할은 index.csv의 split 그대로 / test 72개에는 정답이 없음
- 실행: CH.4 폴더에서 python Main.py (전체 저장), python Main.py A C flow (일부만), python Main.py check (판정 결과 출력)
- 목표 6개 모두 이 데이터로 진행할 수 있음(정비 정책은 정비 이력까지 사용)

5. 고장 위험 예측 (연주 설비)

5.1 문제 정의와 정답 현황

시나리오마다 6시간 간격의 13개 시점에서 "지금부터 6시간(또는 24시간) 안에 고장이 날까"를 맞히는 이진 분류입니다. 정답(labels)이 빈칸인 검열 시점은 제외합니다. 학습과 검증은 시나리오 단위로 나눴습니다.

위험 구간	train 시점 수 (고장)	validation 시점 수 (고장)	고장 비율
24시간	1919 (217)	639 (70)	약 11%
6시간	2508 (52)	837 (16)	약 2%

5.2 특징과 모델

- 특징 94개: 정답 시점 이전 6시간·12시간 구간에서 센서별 평균, 표준편차, 최솟값, 최댓값, 마지막 값, 시간당 기울기 + 정지·결측·정비·이상치 행 비율 + 마지막 정비 이후 경과 시간. 정지·결측·정비 행은 센서 요약에서 제외
- 모델: 로지스틱 회귀(표준화, 균형 가중), 랜덤 포레스트(300그루, 균형 가중). 기준선은 항상 같은 확률을 예측(PR-AUC = 고장 비율)
- 경보 임계값은 train 시나리오의 5-fold 교차검증 예측에서 F1이 최대인 값으로 선택하고, validation은 평가에만 사용
- 평가 지표: 고장이 드물어 정확도 대신 PR-AUC, ROC-AUC, 정밀도(경보 중 진짜 비율), 재현율(실제 고장 중 잡은 비율)

5.3 결과

위험 구간	모델	PR-AUC	ROC-AUC	임계값	경보 수	적중	헛경보	놓침	정밀도	재현율
24시간	기준선(고장 비율)	0.110	0.500	-	-	-	-	-	-	-
24시간	로지스틱	0.756	0.923	0.745	78	55	23	15	0.705	0.786
24시간	랜덤 포레스트	0.762	0.926	0.566	63	52	11	18	0.825	0.743
6시간	기준선(고장 비율)	0.019	0.500	-	-	-	-	-	-	-
6시간	로지스틱	0.246	0.918	0.921	29	8	21	8	0.276	0.500
6시간	랜덤 포레스트	0.489	0.923	0.323	37	13	24	3	0.351	0.812

※ 적중 = 경보가 울린 시점 중 실제 고장(TP), 헛경보 = 고장이 아닌데 울린 경보(FP), 놓침 = 울리지 않았지만 고장이었던 시점(FN). 임계값은 train 교차검증으로 선택했고 정밀도·재현율은 validation에서 측정했습니다.

24시간 위험: PR-AUC 0.76(찍는 수준 0.11)로 찍기보다 훨씬 잘 맞힘. 랜덤 포레스트 기준 경보 63번 중 52번 적중(정밀도 0.83), 실제 고장 70건 중 52건 포착(재현율 0.74). 6시간 위험은 고장 표본이 16개뿐이라 수치가 불안정하며 PR-AUC 0.49로 24시간보다 어려움.

5.4 재현율 0.8 이상을 지킬 때의 정밀도 (24시간)

모델	임계값 선택 방식	임계값	경보	적중	헛경보	놓침	정밀도	재현율
랜덤 포레스트	train으로 정함 (현실적)	0.392	84	57	27	13	0.679	0.814
랜덤 포레스트	validation 최적 (낙관적, 상한)	0.456	76	56	20	14	0.737	0.800
로지스틱	train으로 정함 (현실적)	0.657	94	58	36	12	0.617	0.829
로지스틱	validation 최적 (낙관적, 상한)	0.739	79	56	23	14	0.709	0.800

- 실제로 쓸 수 있는 값은 "train으로 정함"이며 랜덤 포레스트 약 0.68, 로지스틱 약 0.62
- 로지스틱의 재현율이 조금 높게 보이는 것은 임계값이 달라서이고 차이는 고장 1건(58건 대 57건). 같은 재현율에서는 랜덤 포레스트의 정밀도가 약간 높고(0.679 대 0.617), PR-AUC도 0.762 대 0.756으로 비슷해 두 모델은 사실상 비슷한 수준

5.5 중요한 특징 (랜덤 포레스트, 24시간)

순위	특징	중요도
1	w6_MLD-LVL_std	0.0949
2	w12_OSC-STK_slope	0.0812
3	w12_MLD-LVL_std	0.0774
4	w12_CONTROL_DELAY_slope	0.0681
5	w12_OSC-STK_std	0.0624
6	w12_CONTROL_DELAY_std	0.0495
7	w12_CONTROL_DELAY_last	0.0357
8	w6_CONTROL_DELAY_last	0.0333

MLD-LVL(몰드 레벨) 변동, OSC-STK(진동 스트로크) 기울기, CONTROL_DELAY(제어 지연) 기울기와 변동 등 센서 값의 변화가 상위를 차지하며 정비 이력이 아니라 센서 변화로 맞히고 있습니다. 특징 이름의 w6·w12는 직전 6시간·12시간 구간을 뜻합니다.

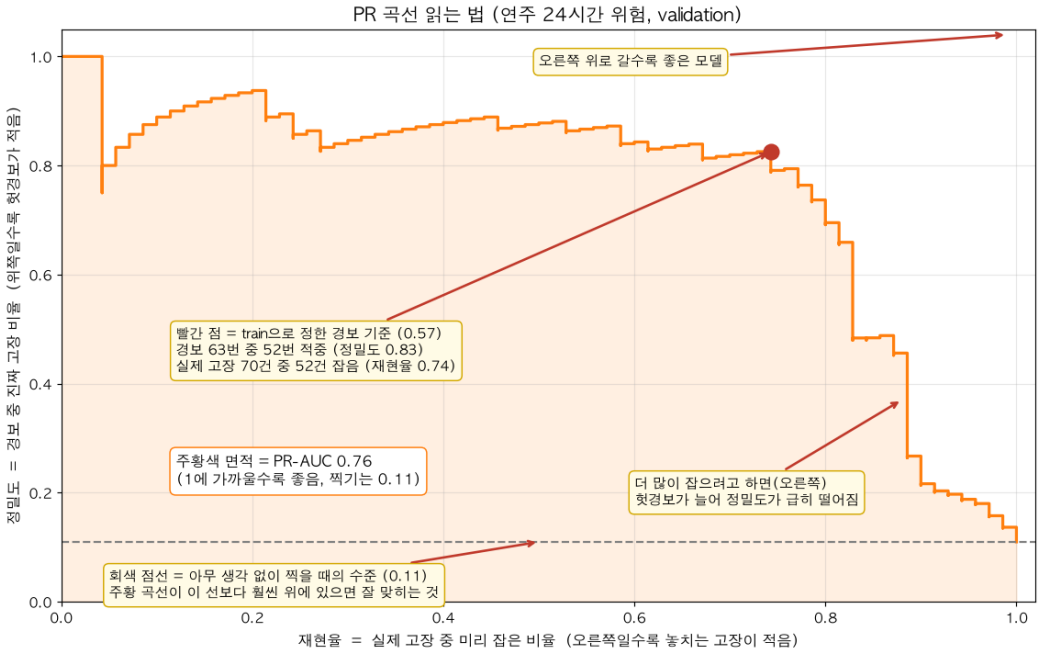


그림 1. PR 곡선 (연주 24시간, 랜덤 포레스트, validation). 오른쪽 위일수록 좋고 회색 점선은 찍는 수준

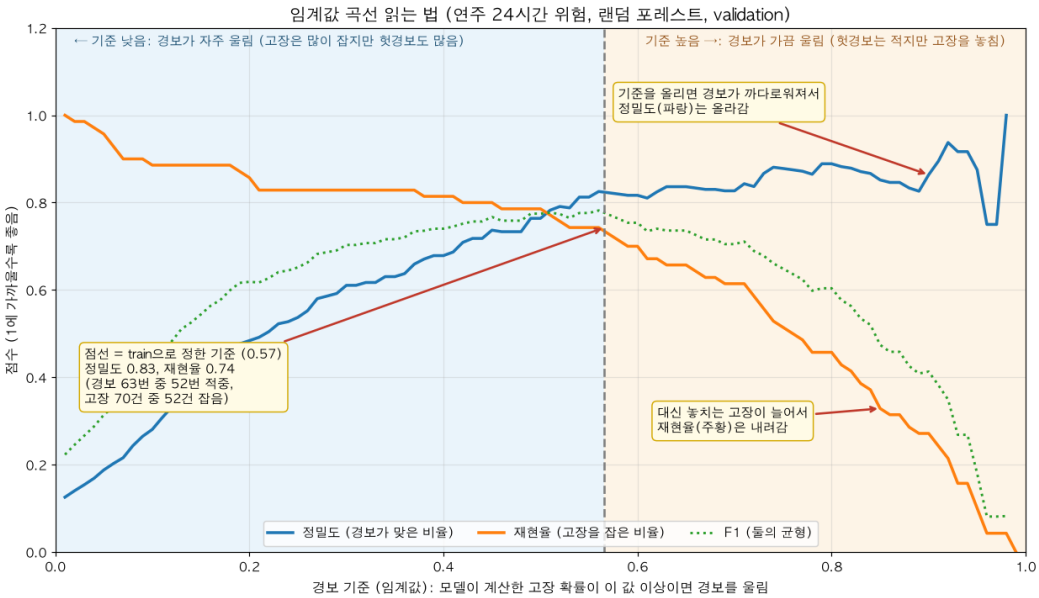


그림 2. 경보 임계값별 정밀도·재현율·F1. 기준을 올리면 정밀도는 오르고 재현율은 내려감

6. 센서별 시간 변화 분석

열화가 있는 시나리오(S0002, 밸브 고착)와 정상 시나리오(S0001)의 연주 센서를 비교했습니다(정지·결측·정비 구간 값은 제외, 1시간 평균).

센서 (의미)	정상 (S0001)	열화 (S0002)
CONTROL_DELAY (제어 지연, 초)	0.08~0.11에서 일정	0.13에서 0.21까지 상승
OSC-STK (진동 스트로크, mm)	4.95 근처에서 일정하게 진동	4.95에서 4.7까지 서서히 하락
MLD-LVL (몰드 레벨, mm)	약 72	약 69로 낮고 흔들림 폭이 변함
WD-LOD (인발 부하 지표)	70~103 사이 진동	75~120으로 진폭 증가
WD-SPD (인발 속도 지표)	약 25시간 주기 진동	거의 같은 모양 (구분에 도움 안 됨)
OSC-FRQ (진동 주파수, Hz)	2로 고정	2로 고정

센서	1시간 평균 변화량의 표준편차 (열화 S0002)	(정상 S0001)
WD-SPD	0.0464	0.0464
WD-LOD	4.8062	4.0768
OSC-STK	0.0213	0.0220
MLD-LVL	0.2328	0.1837
CONTROL_DELAY	0.0027	0.0027

- 변화 속도는 정상과 열화가 비슷하고, 구분은 값의 수준과 한쪽으로의 이동에서 나옴. 이는 모델이 기울기·변동 특징에 의존하는 것과 일치
- 시나리오 한 쌍의 예시이므로 고장 모드(밸브 고착, 마찰, 제어 지연)에 따라 모양이 다를 수 있음

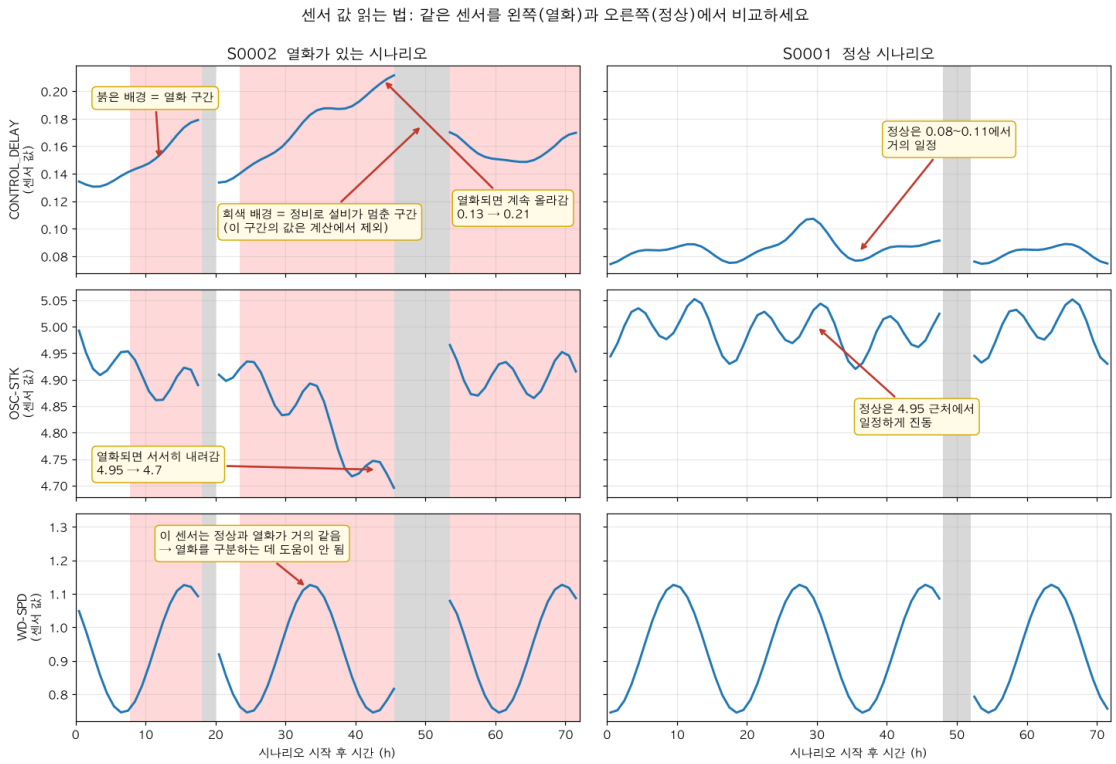


그림 3. 센서 값의 시간 변화 (왼쪽 열화 시나리오, 오른쪽 정상 시나리오). 붉은 배경은 열화, 회색은 정비 정지 구간

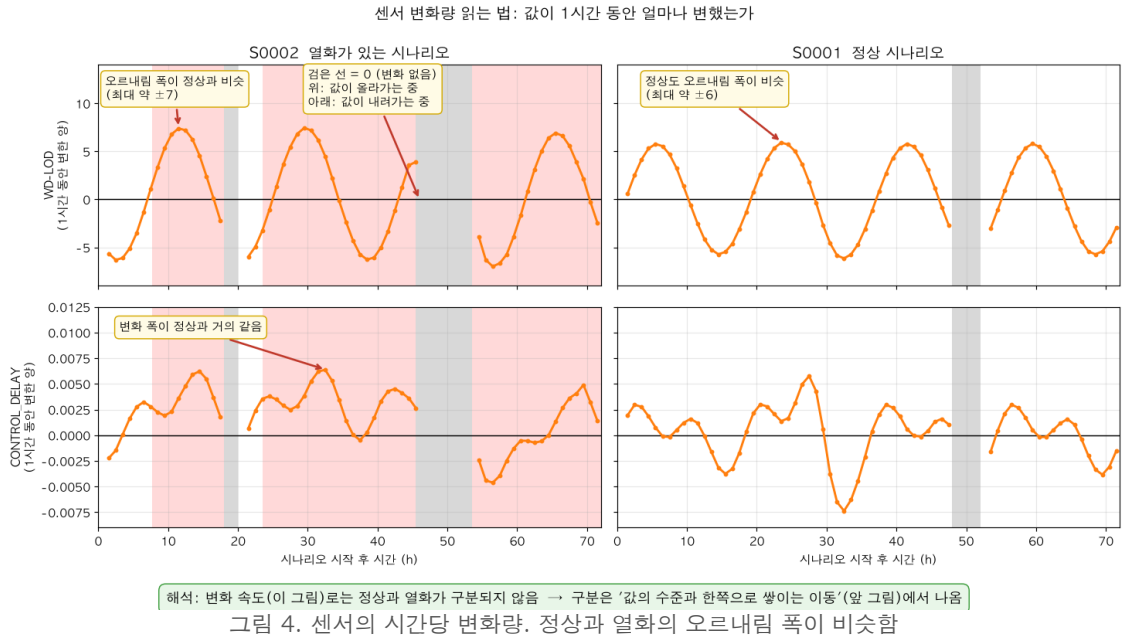


그림 4. 센서의 시간당 변화량. 정상과 열화의 오르내림 폭이 비슷함

7. 검증과 발견·수정한 문제

7.1 독립 검증

- 전처리: 원본 청크를 별도 코드로 다시 읽어 행 수, 결측, 정지, 정비 구간 행 수가 7개 설비 모두 일치. 이상치 규칙은 순수 numpy 반복문으로 다시 구현해 이상치가 많은 시나리오와 대조(불일치 0건)
- 데이터셋: 정답 3종, flow 3종이 원본과 행·값·시각·경과 초가 일치(diagnostics는 밀리초 표기만 초 단위로 줄였고 경과 초 열에는 보존). 정비 이력 6종은 청크를 csv 모듈로 직접 읽어 대조해 일치. flow의 SOURCE_ID 79,425건이 모두 센서 파일에 존재
- 모델링: 시점 이후 센서 행을 삭제하고 특징을 다시 만들었을 때 3,800개 값이 모두 동일(미래 정보 미사용). pandas로 일부 특징을 독립 계산해 45개 값이 모두 일치. 정답(GT_)·판정 표시(IS_) 열이 특징에 섞이지 않음

7.2 검증 중 발견해서 고친 문제

문제	원인	조치와 결과
이상치 과다 (B 307,960행, E1 1,354행 등)	시나리오 초반에 척도(MAD)를 계산할 수 없을 때 척도 하한으로 대체해 완만한 상승이 이상치로 잡힘. B는 코일 안의 용접선 위치별 값 차이를 비교	판정 불가 행은 이상치로 보지 않음, B는 같은 용접 위치끼리 비교, E는 창 5개로 축소 → B 1,469행, E1 13행
의심 청크만 점검 (결측 88% 누락)	정지 시간이 긴 청크가 선택되는 구조	전 시나리오 전수 점검으로 변경
정답 파일 숫자 표기 변경 (0이 0.0, 1이 1.0)	빈칸이 있는 열이 소수 형식으로 읽힘	원본 글자 그대로 저장하도록 수정 후 원본과 글자 단위로 대조
index.csv 열 유실, 새 폴더에서 오류	일부 설비만 저장할 때 기존 내용을 덮어씀	기존 내용에 합치고 없는 열은 빈칸으로 처리
Main.py 실행해도 파일이 생기지 않음	판정 결과를 출력만 하도록 되어 있었음	Main.py가 데이터셋을 저장하도록 변경 (전체 재생성과 이전 결과 일치 확인)
모델 실행 시 경고 반복	센서 파일의 정답 열(GT_)을 읽을 때 타입 혼합 경고	정답 열을 읽지 않도록 수정(경고 해소, 정답 열 혼입 방지)

8. 한계와 향후 과제

한계	영향
합성 데이터	실제 설비에서 같은 성능이 나온다는 보장이 없음
validation 고장 표본이 적음 (24시간 70건, 6시간 16건)	정밀도·재현율이 표본 몇 건에 따라 크게 흔들림(정밀도 0.68은 ±0.1 정도의 불확실성). 6시간 결과는 신뢰하기 어려움
test 72개 시나리오에 정답이 없음	test 예측은 아직 만들지 않았고 최종 평가는 별도
센서 변화 그림이 시나리오 한 쌍의 예시	고장 모드별 모양 차이는 추가 확인 필요

향후 과제

- 과거 구간 길이(1시간, 24시간 등)와 특징을 바꿔 비교, 시나리오를 다시 뽑는 부트스트랩으로 불확실성 확인
- test 시나리오의 위험 예측 생성(정답 없이 센서만 사용)
- 정비 이력(history)을 활용한 특징 추가, 고장 모드별 성능 확인, 다른 모델과 하이퍼파라미터 비교
- 팀 공통 규칙 합의: 과거 구간 길이, 분할(index.csv의 split), GT_ 열 제외, 시점 이전 정보만 사용
- 다른 파트(이상 탐지, 상태·원인 진단, 잔여수명, 정비 정책, 공정 품질)는 같은 전처리 데이터셋에서 시작 가능

부록. 폴더 구조와 실행 명령

위치 (CH.4 기준)	내용
Main.py, src/	전처리 파이프라인 (config, data, detect, screen, zoom, export)
Data/Raw/	원본 입력 (chunks, manifest.json, 정답, flow, 설명서)
Data/Processed/Scenarios/	시나리오별 전처리 데이터셋 (3.0GB)
jungmin/	고장 위험 예측 (config, features, models, Main, plot_sensors, explain_charts)
jungmin/outputs/	특징 표, 예측, 임계값 표, 중요도, 그림, summary.csv
jungmin/report/	이 보고서

명령 (CH.4 폴더에서 실행)	동작
python Main.py	전처리 데이터셋 전체 저장 (설비 7개, flow, 정답, history)
python Main.py check C	연주 판정 결과를 화면에 출력 (저장 안 함)
python jungmin/Main.py	연주 6시간·24시간 고장 위험: 특징 → 학습·평가 → 비교표, 그림 표시
python jungmin/Main.py C 24H reuse noshow	특징 표 재사용, 그림은 저장만
python jungmin/plot_sensors.py	센서별 시간 변화 그림
python jungmin/explain_charts.py	차트 읽는 법을 적은 해설 그림 4장